



Politechnika  
Wrocławska

# Singular Value Decomposition

**Autor**

Sylwia Badur, 241226

# Zawartość prezentacji:

- Czym jest SVD?
- Opis matematyczny,
- Zastosowania,
- Metody wyznaczania SVD,
- Wybrane środowisko programistyczne i narzędzia,
- Realizacja projektu - stan.

# SVD - Singular Value Decomposition

- Rozkład według wartości osobliwych (szczególnych),
- Tzw. faktoryzacja,
- Korzystamy z tego, że macierze można rozłożyć na komponenty rotujące i rozciągające, <https://www.youtube.com/watch?v=EokL7E6o1AE> - odnośnik
- Rozkład macierzy  $A$  wymiaru  $m \times n$  na iloczyn trzech specyficznych macierzy jest **unikalny**,
- Stosowany do redukcji wymiaru macierzy.

# Opis matematyczny

Możemy przedstawić **każdą** macierz  $A$  ( $m \times n$ ) w postaci rozkładu  $U\Sigma V^T$

, gdzie:

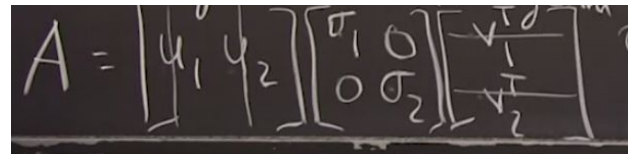
$U$  ( $m \times m$ ) i  $V^T$  ( $n \times n$ ) są macierzami ortogonalnymi - kolumny są zestawami ortonormalnymi  $U^{-1} = U^T, V^{-1} = V^T$

$\Sigma$  ( $m \times n$ ) to macierz diagonalna z nieujemnymi wartościami osobliwymi (non-negative entries on diagonal) uporządkowanymi w porządku malejącym,

Korzysta się w tym celu z dwóch równań, które należy rozwiązać:

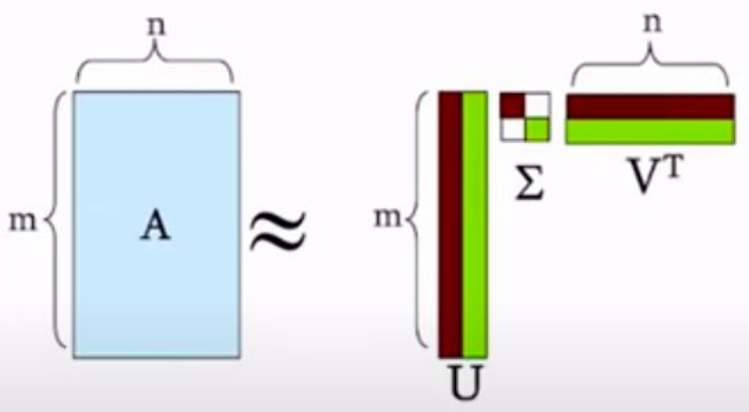
$$A^T A = V \Sigma^T \Sigma V^T$$

$$AV = U \Sigma$$


$$A = \begin{bmatrix} u_1 & u_2 \end{bmatrix} \begin{bmatrix} \sigma_1 & 0 \\ 0 & \sigma_2 \end{bmatrix} \begin{bmatrix} v_1^T \\ v_2^T \end{bmatrix}$$

Macierze mają rzeczywiste wartości

# Opis matematyczny

$$A \approx U \Sigma V^T = \sum_i \sigma_i \mathbf{u}_i \circ \mathbf{v}_i^T$$


Rys. 1: Wizualnie przedstawiony koncept techniki SVD

# Wartości osobliwe macierzy

Pierwiastki kwadratowe wartości własnych macierzy  $A^T A$ , gdzie macierz  $A^T$  jest sprzężona do  $A$ .

Wartościami osobliwymi nazywa się wartości położone na przekątnej macierzy  $\Sigma$   $\sigma_i = \Sigma_{ii}$ .

Liczba niezerowych wartości osobliwych jest równa rzędowi macierzy  $A$ .

Natomiast kolumny  $U$  i  $V$  są nazywane osobliwymi wektorami lewo- oraz prawostronnymi.

# Własności

Jeżeli macierz  $A$  jest macierzą nieosobliwą, to można tak dobrać macierze  $U$  oraz  $V$ , by jej wszystkie wartości osobliwe były dodatnie. Jeżeli którakolwiek wartość osobliwa macierzy jest równa zero, to macierz ta jest macierzą osobliwą.

Wartość bezwzględna wyznacznika macierzy kwadratowej  $A$  jest iloczynem wszystkich wartości osobliwych tej macierzy.

$$|\det(A)| = \sigma_1 \sigma_2 \sigma_3 \dots \sigma_n$$

# Zastosowania SVD

- Techniki z obszaru Machine Learning,
- Redukcja danych do specyficznego problemu,
- Baza dla PCA (principle component analysis),
- Systemy rekomendacyjne - Amazon, Netflix,
- Rozpoznawanie twarzy - Facebook,
- Algorytmy rankingowania stron internetowych - Google,
- Przetwarzanie obrazów,
- Sterowanie procesami.




# Algorytm SVD - klasyczna metoda z użyciem eigenvalues i eigenvectors

1. Wyznaczenie macierzy  $A^T$
2. Obliczenie macierzy  $A^T A$  oraz  $A A^T$
3. Obliczenie rzędu dla dwóch macierzy. Przyjęcie właściwej macierzy o niższym rzędzie.
4. Obliczenie wartości własnych macierzy - pierwiastki wartości własnych.
5. Określić liczbę niezerowych wartości własnych -  $r$ .
6. Znaleźć ortonormalne wartości własne macierzy.
7. Stworzenie macierzy ortogonalnej  $V$ .
8. Stworzenie macierzy  $\Sigma$  z pierwiastków kwadratowych wartości własnych.
9. Znalezienie pierwszych  $r$  wektorów kolumnowych  $U$ .
10. Uzupełnienie  $U$  wykorzystując ortogonalizację Grama-Schmidta.

# Block SVD power method

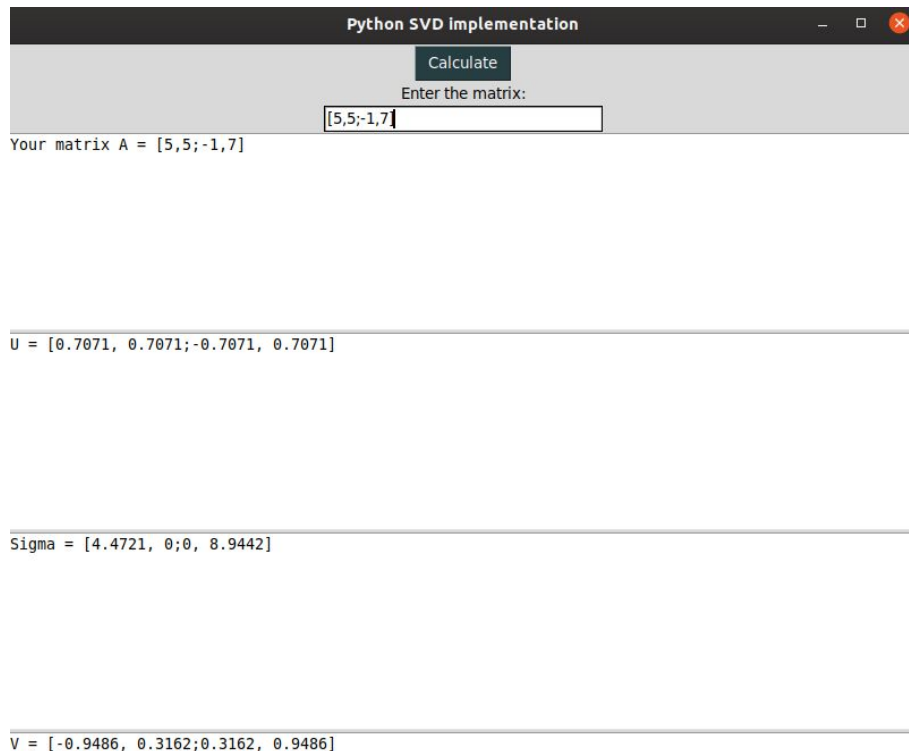
1. Tworzymy macierz  $A^T A$  lub  $A A^T$  w zależności od wymiaru  $A$ .
2. Losowo generujemy macierz  $Q$ .
3. Dokonujemy jej dekompozycji na QR (ortogonalna i trójkątna górna).
4. Iteracyjnie dokonujemy operacji mnożenia macierzy  $A$ ,  $Q$  oraz dekompozycji na  $Q$  i  $R$ , tak by błąd między kolejnymi iteracjami (błąd średniokwadratowy) malał i osiągnął wartość poniżej pewnego progu.
5. Algorytm zbiega tak, by macierz  $Q$  stanowiła eigenvectors a  $R$  eigenvalues.
6. Wyznaczamy wartości osobliwe jako pierwiastki z diagonalu macierzy  $R$ .
7. W zależności od wymiarów macierzy  $A$  wyznaczamy  $U$  oraz  $V$  na różne sposoby.
8. Jest to metoda iteracyjna, siłowa.

# Wybrane technologie i środowisko programistyczne



# Co do tej pory zrealizowano?

- Podstawy implementacji algorytmu na znanym przykładzie (znane A),
- Prosty interfejs graficzny - przycisk, pola tekstowe, wykonanie funkcji, wyświetlenie wyniku obliczeń



The screenshot shows a window titled "Python SVD implementation". It features a "Calculate" button and a text input field labeled "Enter the matrix:". The input field contains the text "[5,5;-1,7]". Below the input field, the text "Your matrix A = [5,5;-1,7]" is displayed. Further down, the results of the SVD calculation are shown in three separate lines, each preceded by a horizontal line:

- $U = [0.7071, 0.7071; -0.7071, 0.7071]$
- $\Sigma = [4.4721, 0; 0, 8.9442]$
- $V = [-0.9486, 0.3162; 0.3162, 0.9486]$



Politechnika  
Wrocławska

# Singular Value Decomposition

**Autor**

Sylwia Badur, 241226